

Софийски университет “Св. Климент Охридски”

Факултет по математика и информатика

Курсов проект

на тема:

Опростяване на биомедицински научни ТЕКСТОВЕ

Студент: Екатерина Хамбарлийска, Ф.Н. 8MI3400767

Магистърска програма: Извличане на информация и откриване на знания

Курс: Откриване на знания в текст

Учебна година: 2025/2026

Преподаватели: проф. д-р Иван Койчев, проф. д-р Преслав Наков, гл. ас. Димитър Димитров, Алексис Датсерис

Декларация за липса на плагиатство

Декларирам, че настоящата курсова работа е моя собствена разработка, като всички използвани източници, идеи, илюстрации, данни и програмен код от други автори са коректно цитирани. Разбирам, че при установяване на плагиатство работата може да бъде оценена със “Слаб”.

Дата: 27 юни 2026 г.

Подпис: _____

Съдържание

Резюме	2
1 Увод	2
2 Изследователски хипотези	3
3 Преглед на областта	3
4 Данни и характеристики	4
4.1 Описание на корпуса	4
4.2 Структура на данните на ниво изречение	4
4.3 Анализ на данните на ниво изречение	5
4.4 Структура на данните на ниво изречение	5
4.5 Предварителна обработка	6
4.6 Анализ на документните данни	6
5 Методи	7
5.1 Изходен модел с Llama 3.1 8B	7
5.2 Дообучаване на FLAN-T5	8
5.3 Дообучаване на BioBART	8
5.4 Многоетапен подход с предсказване на операции	8
5.5 Многоетапен подход с истински етикети	8
5.6 BioBART с терминологично знание	9
5.7 Документно опростяване с Llama 3.1 8B	9
5.8 Документно опростяване с дообучен BioBART	10
5.9 Документно опростяване, подпомогнато от резюме	10
6 Експерименти, резултати и дискусия	10
6.1 Изчислителна среда	10
6.2 Резултати от класификацията на операции	11
6.3 Дискусия на директните генеративни модели	11
6.4 Дискусия на многоетапния подхода	11
6.5 Дискусия на Knowledge-Enhanced BioBART	12
6.6 Резултати при документно опростяване	12
6.7 Проверка на изследователските хипотези	13
7 Заключение и бъдеща работа	15
8 Използвана литература	16

Резюме

Курсовият проект разглежда задачата за опростяване на биомедицински научни текстове. Научната литература предоставя надеждна и актуална информация, но често е трудна за разбиране от неспециалисти поради използването на специализирана терминология, статистически данни и сложен научен стил. Основната цел на проекта е разработването и сравнението на различни подходи за опростяване на биомедицински изречения и документи от корпуса Cochrane-auto [1], използван в задачите Task 1.1 и Task 1.2 на CLEF SimpleText [2].

Реализирани и оценени са няколко подхода. Като отправна точка е използван голям езиков модел без допълнително обучение. Разработени са модели, основани на FLAN-T5 и BioBART, които са дообучени върху корпуса. Допълнително са изследвани подходи, използващи граф на знанията за подпомагане на лексикалното опростяване, както и многоетапен подход, при който първо се определя необходимата операция за опростяване, а след това се генерира крайният текст. Проведени са и експерименти за опростяване на цели документи.

1 Увод

Опростяването на научен текст представлява задача от областта на обработката на естествения език, при която сложен текст се преобразува в по-разбираема форма, без да се губи основната информация. В биомедицинската област тази задача е особено важна, тъй като неспециалистите често се нуждаят от достъп до надеждна медицинска информация, а научните публикации обикновено съдържат специализирана терминология, статистически данни и сложни езикови конструкции.

В настоящата работа се разглеждат задачите за опростяване на отделни изречения и на цели документи от научни публикации (*Task 1.1 – Sentence-level Scientific Text Simplification* и *Task 1.2 – Document-level Scientific Text Simplification*) [2]. При първата задача входът представлява сложно биомедицинско изречение, а изходът е негова по-достъпна и разбираема версия. При втората задача входът е цял научен документ, който трябва да бъде преобразуван в по-разбираем текст, като се запазят основните факти и логическата последователност.

Пример за опростяване на изречение:

Вход: We identified 34 RCTs with 3565 participants.

Изход: We found 34 studies involving 3565 participants.

И при двете задачи основното предизвикателство е запазването на смисъла и фактическата коректност на текста, като същевременно се използва по-достъпен език и се намалява сложността на изложението. При опростяването на цели документи допълнително възниква необходимост от запазване на логическата свързаност между отделните части на текста и на последователното представяне на информацията.

В рамките на проекта са разработени и сравнени различни подходи за автоматично опростяване на биомедицински текстове, както на ниво изречение, така и на ниво документ, с цел да се оцени доколко те подобряват разбираемостта на информацията, без да нарушават нейното съдържание.

2 Изследователски хипотези

В рамките на настоящата работа са формулирани следните изследователски хипотези:

- H1: Дообучените върху биомедицински данни модели постигат по-добри резултати при опростяване на текст в сравнение с общо предназначени големи езикови модели.
- H2: Използването на специализиран биомедицински модел (BioBART) води до по-качествено опростяване на биомедицински текстове в сравнение с общ Transformer-базиран модел (FLAN-T5).
- H3: Използването на допълнителни знания под формата на граф от понятия подобрява качеството на лексикалното опростяване и води до по-високи стойности на метриката SARI.
- H4: Разделянето на задачата на последователни операции за опростяване (изтриване, преформулиране, разделяне и запазване) има потенциал да подобри резултатите спрямо директното генериране на опростен текст.
- H5: Съществува компромис между степента на опростяване и запазването на съдържанието. Подходите, които постигат по-високи стойности на SARI чрез по-агресивни редакции, могат да доведат до по-ниски стойности на BLEU и BERTScore поради отдалечаване от оригиналния текст и референтното опростяване.
- H6: При многоетапните архитектури качеството на класификацията на операциите за опростяване е основният фактор, определящ крайното качество на генерирания текст.
- H7: Добавянето на контекст на ниво документ не води непременно до по-добро качество на опростяването в сравнение с опростяването на отделни изречения.

3 Преглед на областта

Текстовото опростяване е активно изследвана задача в областта на обработката на естествен език. Ранните подходи често използват правила, речници и статистически модели, докато съвременните системи се базират основно на невронни мрежи и Трансформър архитектури [3].

Съвременните модели като BART [4] и T5 [5] използват енкодер-декодер архитектура и attention механизъм. Те са подходящи за задачи, при които входният текст трябва да бъде преобразуван в нов текст, включително текстово опростяване.

Биомедицинското текстово опростяване представлява предизвикателство поради наличието на специализирана терминология, съкращения и статистически данни. Според изследване на Ondov и съавтори съвременните подходи все по-често комбинират невронни модели с външни източници на знания с цел подобряване на опростяването на специализирани термини [3].

Големите езикови модели могат да се използват като базова линия чрез инструкции на естествен език, без допълнително обучение върху конкретен набор от данни.

4 Данни и характеристики

4.1 Описание на корпуса

В настоящото изследване е използван корпусът Cochrane-auto, който съдържа двойки от сложни биомедицински текстове и техните опростени версии. Данните произхождат от *Cochrane Systematic Reviews* [1], където научните абстракти са свързани със съответните резюмета, предназначени за неспециализирана аудитория.

Корпусът е създаден чрез автоматично подравняване. Позволява изследването на различни операции по текстово опростяване. В експериментите са използвани две представяния на корпуса:

- **sentence-level представяне** за Task 1.1, при което всеки пример представлява отделно изречение;
- **document-level представяне** за Task 1.2, при което всички изречения от един документ са обединени в общ входен текст.

Размерите на двата варианта на корпуса са представени в Таблица 1.

Таблица 1: Размери на sentence-level и document-level наборите

Раздел	Sentence-level	Document-level
Обучаващ	11 510	849
Валидационен	1 697	119
Тестов	1 512	117

4.2 Структура на данните на ниво изречение

Всеки запис съдържа сложно изречение, неговата опростена версия и допълнителна информация за позицията му в документа.

Таблица 2: Основни полета на ниво изречение

Поле	Описание
<code>pair_id</code>	Идентификатор на Cochrane документа
<code>para_id</code>	Индекс на параграфа
<code>sent_id</code>	Индекс на изречението
<code>complex</code>	Оригинално сложно биомедицинско изречение
<code>simple</code>	Опростена версия на изречението
<code>label</code>	Операция по опростяване: <code>rephrase</code> , <code>delete</code> , <code>split</code> , <code>ignore</code> , <code>merge</code> или <code>none</code>
<code>simp_sent_id</code>	Идентификатор на опростеното изречение
<code>doc_pos</code>	Нормализирана позиция на изречението в документа
<code>doc Quint</code>	Частта от документа, в която се намира изречението
<code>doc_len</code>	Общ брой изречения в документа

4.3 Анализ на данните на ниво изречение

За изследване на характеристиките на корпуса бяха анализирани разпределението на етикетите, дължината на изреченията и коефициентът на компресия. Резултатите са представени на Фигура 1.

Най-често срещаната операция е `rephrase`, която представлява приблизително 45% от обучаващите примери. Следва `delete` с приблизително 35%. Останалите операции са значително по-слабо представени.

Средната дължина на сложните изречения е приблизително 26 думи, опростените версии съдържат средно около 15 думи. В приблизително две трети от примерите опростеният текст е по-кратък от оригиналния. Средният коефициент на компресия е около 0,7, като стойност под 1 означава, че опростената версия е по-кратка.

4.4 Структура на данните на ниво изречение


Основните полета са представени в Таблица 3.

Таблица 3: Основни полета в document-level набора

Поле	Описание
<code>pair_id</code>	Уникален идентификатор на Cochrane документа
<code>complex</code>	Пълният оригинален биомедицински абстракт
<code>simple</code>	Съответният опростен документ
<code>para_id</code>	Позиции на параграфите, включени в документа
<code>label</code>	Списък от операции в документа
<code>simp_sent_id</code>	Идентификатори на опростените изречения
<code>doc_len</code>	Брой изречения в оригиналния документ

Полето `label` не представлява един общ етикет за документа. То съдържа последователността от операции, приложени към отделните изречения в него.

Анализ на корпуса Cochrane-auto



Фигура 1: Анализ на sentence-level представянето на Cochrane-auto

4.5 Предварителна обработка


Преди обучението бяха заредени обучаващият, валидационният и тестовият набор, като беше извършена проверка за липсващи стойности и коректност на данните.

За експериментите на ниво изречение беше използвана обработена версия на корпуса, съдържаща само примерите с етикети **rephrase**, **ignore** и **split**. Примерите с етикети **delete**, **merge** и **none** бяха премахнати, тъй като не са подходящи за директно обучение на генеративен модел. След обработката наборът съдържа 6,742 обучаващи, 984 валидационни и 892 тестови примера.

Входните и целевите изречения бяха токенизирани с помощта на токенизатора на съответния модел. Максималната дължина на входните последователности беше ограничена до 256 токена, а на целевите – до 128 токена. Допълващите токени в целевите последователности бяха маскирани, така че да не участват при изчисляването на функцията на загуба по време на обучението.

4.6 Анализ на документните данни

Обобщеният анализ е представен на Фиг. 2. Графиките показват размерите на разделите, разпределението на операциите на ниво изречение в документите, сравнението между дължините на оригиналните и опростените текстове и медианния брой думи. Наборът съдържа 849 обучаващи, 119 валидационни и 117 тестови документа. Най-често срещаната операция е **rephrase**, следвана от **delete**. Наблюдава се значително



Фигура 2: Анализ на document-level представянето на Cochrane-auto

съкращаване на текстовете. В обучаващия набор медианната дължина намалява от 340 думи в оригиналния документ до 187 думи в опростената версия. Над 96% от опростените документи са по-кратки от съответните оригинални текстове. Средният коефициент на компресия е приблизително 0,57, което показва, че опростените документи запазват малко повече от половината от дължината на оригиналните абстракти.

5 Методи

5.1 Изходен модел с Llama 3.1 8B

Като отправна точка за сравнение беше използван моделът Llama 3.1 8B, стартиран чрез Ollama. Моделът не беше дообучаван върху използвания корпус. За всяко входно изречение се подава инструкция да го пренапише за неспециализирана аудитория.

Инструкцията изисква запазване на първоначалния смисъл, използване на ясен език, замяна на сложната медицинска терминология и избягване на информация, която не присъства в оригиналния текст. По този начин Llama 3.1 8B служи за сравнение с моделите, дообучени върху конкретните данни.

5.2 Дообучаване на FLAN-T5

FLAN-T5 е модел за преобразуване на един текст в друг. Всяко сложно биомедицинско изречение се подава като вход, а съответното опростено изречение се използва като желан изход. Моделът се дообучава върху обучаващата част на корпуса, за да усвои характерните промени при биомедицинското текстово опростяване.

5.3 Дообучаване на BioBART

BioBART е вариант на BART, предварително приспособен към биомедицински текстове. Моделът се състои от кодираща част, която обработва входното изречение, и декодираща част, която създава неговата опростена версия. Подобно на FLAN-T5, BioBART се дообучава върху двойки от сложни и опростени изречения.

5.4 Многоетапен подход с предсказване на операции

Реализиран е многоетапен подход, при който първо се определя необходимата операция по опростяване, а след това се създава крайният текст.

В първия етап модел за класификация, основан на PubMedBERT, предсказва една от четири операции: преформулиране, премахване, запазване или разделяне на изречението. Те съответстват на етикетите `rephrase`, `delete`, `ignore` и `split`. Поради неравномерното разпределение на класовете при обучението са използвани тегла, обратно пропорционални на честотата на всеки клас.

Във втория етап предсказаната операция определя обработката на изречението:

- `delete` — връща се празен изход;
- `ignore` — запазва се оригиналното изречение;
- `rephrase` — използва се дообученият BioBART;
- `split` — използва се дообученият BioBART.

Целта е задачата да бъде разделена на избор на подходящо действие и последващо създаване на опростен текст.

5.5 Многоетапен подход с истински етикети

За да се оцени многоетапният подход независимо от грешките на модела за класификация, е реализиран вариант, който използва истинските етикети от корпуса.

Изпълнението на операциите остава непроменено:

`rephrase` → BioBART,
`split` → BioBART,
`ignore` → оригиналното изречение,
`delete` → празен изход.

Този експеримент представя теоретична горна граница за многоетапния подход. Той позволява да се разграничат грешките при избора на операция от ограниченията на генеративния модел.

5.6 BioBART с терминологично знание

Изследван е подход за автоматично извличане на терминологични съответствия от обучаващите данни. Целта е да бъдат открити двойки от сложен биомедицински термин и негово по-разбираемо съответствие, без те да бъдат задавани ръчно.

Графът се изгражда чрез колоните `complex` и `simple`. За всяка двойка се сравняват сложното и опростеното изречение. Чрез правила за съпоставяне се откриват фрагменти, заменени с по-разбираеми изрази.

Например от двойка, съдържаща `hypertension` в сложното изречение и `high blood pressure` в опростеното, се извлича съответствието:

`hypertension` → `high blood pressure`.

Възлите представят термините и техните опростени форми, а ребрата описват отношението „опростява се като“. За всяко ребро се съхраняват честотата на срещане и броят на подкрепящите двойки изречения.

След извличането се прилагат правила за отстраняване на шум. Премахват се служебни и прекалено общи думи, пунктуационни знаци, числа, твърде кратки фрази, неправилно образувани думи и фрагменти, зависещи от конкретния контекст. След окончателното пречистване графът съдържа 66 възела и 34 ребра.

С помощта на графа е реализиран вариант на BioBART, подпомогнат от терминологично знание. Дообученият модел не се обучава повторно, а получава информацията от графа непосредствено преди създаването на опростения текст.

За всяко входно изречение се проверява дали съдържа термин от графа. Търсенето не отчита разликата между главни и малки букви и включва прости форми за единствено и множествено число. При откриване на термин към входа се добавя кратък списък с подходящите опростявания.

За да не се увеличава прекомерно дължината на входа, към едно изречение се добавят най-много три терминологични съответствия. Ако не бъде открит подходящ термин, се използва обичайният вход без допълнителна информация.

Целта е да се установи дали явно предоставените терминологични съответствия подпомагат модела при избора на по-разбираеми изрази.

5.7 Документно опростяване с Llama 3.1 8B

Първият метод за опростяване на цели документи използва Llama 3.1 8B без допълнително обучение. На модела се подава целият научен абстракт с инструкцията да го пренапише за широка аудитория, като запази основните резултати и заключения и премахне несъществените методологични подробности.

Този метод служи като отправна точка за оценяване.

5.8 Документно опростяване с дообучен BioBART

Вторият метод използва BioBART, дообучен върху двойки от сложни и опростени документи. Входът съдържа целия научен абстракт, а желан изход е съответното резюме за неспециализирана аудитория.

За разлика от изреченческите опити, при този метод моделът разполага с контекста на целия документ. Това му позволява да отчита връзките между отделните изречения и да създава по-свързан опростен текст.

5.9 Документно опростяване, подпомогнато от резюме

Третият документен метод използва два последователни етапа. В първия етап Llama 3.1 8B създава кратко резюме на оригиналния биомедицински документ. Резюмето трябва да запази изследваната група, приложената намеса, основните резултати и заключенията, като премахне ненужните подробности.

Във втория етап генерираното резюме и оригиналният документ се подават заедно на дообучения документен BioBART. Резюмето служи като ориентир за най-важната информация, която трябва да бъде запазена в крайния опростен текст.

BioBART не се дообучава повторно за този експеримент. Използва се същият модел от предходния документен метод, което позволява да се оцени самостоятелният принос на допълнителното резюме. Методът е вдъхновен от подхода за документно опростяване, предложен от Marturi и Elwazzan [6]. При него кратко резюме на документа се използва като ориентир при създаването на опростения текст. ¶

6 Експерименти, резултати и дискусия

6.1 Изчислителна среда

Експерименти бяха проведени в облачната платформа RunPod, която предоставя виртуални среди с достъп до специализиран графичен хардуер за задачи, свързани с машинно обучение и обработка на естествен език. RunPod позволява бързо създаване на GPU-базираны среди с предварително конфигурирани драйвери и софтуерни зависимости, което улеснява провеждането на експерименти с дълбоки невронни мрежи. Използваният графичен ускорител предоставя 24 GB графична памет и е подходящ за дообучаване и извеждане на резултати от средноголеми Transformer модели. Конфигурацията осигурява достатъчно ресурси за обучението на FLAN-T5, BioBART и класификационните модели, използвани в настоящата работа.

Всички експерименти бяха реализирани чрез Python и библиотеките Hugging Face Transformers, PyTorch, Datasets и Evaluate, като при наличие на графичен ускорител се използва CUDA за ускоряване на обучението и генерирането.

6.2 Резултати от класификацията на операции

Класификаторът, базиран на PubMedBERT/BioBERT, беше обучен да предсказва една от четири операции: `rephrase`, `delete`, `ignore` и `split`. Резултатите са представени в Таблица 4.

Таблица 4: Резултати от класификацията на операции

Модел	Accuracy	Macro F1	Weighted F1
PubMedBERT/BioBERT classifier	0.477	0.375	0.482

Резултатите показват, че класификаторът не е достатъчно надежден. Особено ниската стойност на Macro F1 показва, че моделът се затруднява при по-слабо представените класове, като `ignore` и `split`. Това е важен проблем, защото грешките на класификатора директно се пренасят във втория етап на pipeline-а.

6.3 Дискусия на директните генеративни модели

Сравнението между Llama, FLAN-T5 и BioBART показва, че дообучаването върху конкретния корпус е съществено за задачата. Zero-shot Llama генерира смислени и четими изречения, но не постига достатъчно добро съответствие с референтните опростявания.

FLAN-T5 показва силно n-gram и семантично припокриване с референциите, което личи от високите BLEU и BERTScore стойности. Въпреки това, по-ниският SARI показва, че моделът често не извършва достатъчно полезни операции по опростяване или запазва твърде много от структурата на оригиналното изречение.

BioBART се представя най-добре според SARI. Това вероятно се дължи на факта, че моделът е предварително адаптиран към биомедицински текстове, което му помага да обработва медицинска терминология и научен стил по-адекватно от общия FLAN-T5 модел.

6.4 Дискусия на многоетапния подхода

Многоетапният подход с класификация на операции има ясна мотивация: не всяко изречение трябва да бъде преформулирано. Някои изречения трябва да бъдат изтрети, други да бъдат запазени, а трети да бъдат преформулирани или разделени. Въпреки това резултатите показват, че реалният класификатор + BioBART pipeline се представя по-слабо от директния BioBART модел.

Основната причина е натрупването на грешки. Ако класификаторът предскаже `delete` за изречение, което трябва да бъде преформулирано, системата връща празен изход. Ако предскаже `ignore` за изречение, което трябва да бъде опростено, системата запазва твърде сложния оригинален текст. По този начин дори сравнително малки грешки в първия етап могат да имат голям негативен ефект върху крайния резултат.

Oracle pipeline експериментът показва какво би се случило, ако класификаторът беше перфектен. Той използва истинските етикети от набора от данни и постига SARI 31.39. Това е значително по-добре от класификатор + BioBART pipeline, но не е категорично по-добро от директния BioBART модел. Следователно action pipeline подходът има потенциал, но само ако класификаторът бъде значително подобрен.

6.5 Дискусия на Knowledge-Enhanced BioBART

След филтриране активният граф съдържа 66 възела и 34 ребра.

При тестовото множество са открити в 138 от 892 примера, което представлява покритие от 15.47%. Това ниско покритие е основната причина подходът да не подобрява цялостния резултат.

Таблица 5 показва резултатите с и без открити KG термини.

Таблица 5: Резултати на Optimized KG-BioBART по подмножества

Subset	Брой примери	SARI	BLEU	BERTScore F1
Всички примери	892	30.40	32.64	0.928
С KG термини	138	36.72	25.62	0.921
Без KG термини	754	29.24	34.07	0.930

Важно е тези subset резултати да не се интерпретират самостоятелно, защото примерите със и без KG термини са различни. Затова беше направено head-to-head сравнение между директен BioBART и KG-BioBART върху едни и същи примери. При subset-а с KG термини KG-BioBART подобрява SARI с около 0.50 пункта, но намалява BLEU и BERTScore. Върху цялото тестово множество KG-BioBART е леко по-слаб от директния BioBART.

Това показва, че графът може да помогне при отделни изречения, но ефектът е ограничен от ниското покритие и риска от въвеждане на нерелевантна или твърде ограничена терминологична информация.

6.6 Резултати при документно опростяване

За оценка на документното опростяване използваме четири показателя. SARI е основната метрика, защото измерва полезните промени в текста. BLEU показва доколко генерираният текст съвпада с референтния опростен текст, а BERTScore F1 измерва смисловата близост. Коефициентът на компресия е отношението между дължината на генерирания текст и дължината на оригинала; по-ниска стойност означава по-силно съкращаване.

Дообученият модел BioBART постига най-високи стойности по SARI, BLEU и BERTScore и показва най-добър общ баланс между опростяване и запазване на съдържанието. BioBART с резюме извежда най-кратки текстове, но това води до по-нисък BLEU и лек спад в SARI. Базовият Llama модел запазва по-голяма част от оригиналния текст, но е най-слаб по трите основни метрики.

Таблица 6: Резултати при документно опростяване

Подход	SARI	BLEU	BERTScore F1	Компресия
Дообучен BioBART	39.23	26.95	0.886	0.551
BioBART с резюме	37.54	10.85	0.876	0.339
Базов модел Llama	36.57	7.02	0.865	0.751

6.7 Проверка на изследователските хипотези

Въз основа на проведените експерименти могат да бъдат оценени предварително формулираните изследователски хипотези.

H1: Дообучените върху биомедицински данни модели постигат по-добри резултати при опростяване на текст в сравнение с общо предназначени големи езикови модели. Хипотезата се потвърждава. Zero-shot Llama 3.1 8B постига SARI 28.25, BLEU 3.60 и BERTScore F1 0.897. За сравнение, дообученият BioBART постига по-висок SARI резултат от 31.86, а FLAN-T5 постига по-високи BLEU и BERTScore стойности. Това показва, че адаптацията към конкретния корпус чрез fine-tuning е важна за задачата. Големият езиков модел генерира четими изречения, но без дообучаване не успява да се доближи достатъчно до стила и структурата на референтните опростявания.

H2: Използването на специализиран биомедицински модел (BioBART) води до по-качествено опростяване на биомедицински текстове в сравнение с общ Transformer-базиран модел (FLAN-T5). Хипотезата се потвърждава частично. BioBART постига по-висок SARI резултат от FLAN-T5: 31.86 спрямо 26.86. Това означава, че BioBART извършва по-подходящи операции по опростяване според основната метрика за text simplification. От друга страна, FLAN-T5 има по-високи BLEU и BERTScore стойности: BLEU 36.57 и BERTScore F1 0.935 спрямо BLEU 30.91 и BERTScore F1 0.932 за BioBART. Следователно BioBART е по-добър според SARI, но FLAN-T5 е по-близък до референтните изречения според lexical и semantic overlap метриците.

H3: Включването на допълнителни знания под формата на граф от понятия подобрява качеството на лексикалното опростяване и води до по-високи стойности на метриката SARI. Хипотезата се потвърждава само локално, но не и за цялото тестово множество. Optimized KG-BioBART подобрява SARI върху subset-а от примери, в които са открити mappings от графа: директният BioBART постига SARI 36.22, а KG-BioBART постига SARI 36.72 върху същите 138 примера. Това е подобрение от приблизително 0.50 SARI пункта.

Върху цялото тестово множество обаче KG-BioBART не подобрява резултата. Директният BioBART постига SARI 30.56 при head-to-head преизчисление, докато Optimized KG-BioBART постига SARI 30.40. Основната причина е ниското покритие

на графа: mappings са открити само в 138 от 892 тестови примера, т.е. 15.47%. Следователно графът може да помогне при отделни изречения, но ефектът му е твърде ограничен, за да подобри общия резултат.

H4: Разделянето на задачата на последователни операции за опростяване има потенциал да подобри резултатите спрямо директното генериране на опростен текст. Хипотезата се потвърждава частично. Реалният classifier + BioBART pipeline не подобрява резултатите спрямо директния BioBART модел. Той постига SARI 27.01, BLEU 22.20 и BERTScore F1 0.932, което е по-слабо от директния BioBART.

Въпреки това oracle action pipeline, при който се използват истинските етикети, постига SARI 31.39, BLEU 34.69 и BERTScore F1 0.931. Това показва, че самата идея за разделяне на задачата има потенциал, ако операцията е известна правилно. На практика обаче текущият класификатор не е достатъчно точен, за да реализира този потенциал.

H5: Съществува компромис между степента на опростяване и запазването на съдържанието. Хипотезата се потвърждава. Резултатите показват ясно напрежение между SARI, BLEU и BERTScore. Например BioBART има по-висок SARI от FLAN-T5, което показва по-добро изпълнение на операции по опростяване, но FLAN-T5 има по-висок BLEU и BERTScore. Това означава, че FLAN-T5 остава по-близо до референцията по повърхностна и семантична близост, докато BioBART извършва по-силни редакции.

Подобен ефект се наблюдава и при KG-BioBART. В subset-a с открити KG термини SARI се подобрява спрямо директния BioBART, но BLEU и BERTScore намаляват. Това показва, че добавеното знание може да насърчи по-активно лексикално опростяване, но понякога отдалечава генерирания текст от конкретната референция или променя формулировката.

H6: При многоетапните архитектури качеството на класификацията на операциите за опростяване е основният фактор, определящ крайното качество на генерирания текст. Хипотезата се потвърждава. Класификаторът за операции постига Accuracy 0.477, Macro F1 0.375 и Weighted F1 0.482, което показва ограничена надеждност. Това води до слабо представяне на classifier + BioBART pipeline-a, тъй като грешките в първия етап директно определят грешното действие във втория етап.

Сравнението с oracle pipeline-a потвърждава този извод. Когато вместо предсказани операции се използват истинските етикети, резултатът се повишава от SARI 27.01 до SARI 31.39. Следователно основното ограничение на многоетапната архитектура е качеството на класификатора, а не само генеративният BioBART компонент.

H7: Добавянето на контекст на ниво документ не води непременно до по-добро качество на опростяването в сравнение с опростяването на отделни изречения. Хипотезата не се потвърждава. Получените резултати показват, че използването на контекст на ниво документ може да подобри качеството на автоматичното опростяване. При експериментите за опростяване на документи дообученият BioBART постига най-висока стойност на SARI – 39.23. Това показва, че предоставянето на допълнителен документен контекст под формата на резюме подпомага модела при генерирането на по-качествени опростени документи.

7 Заключение и бъдеща работа

В настоящия проект бяха изследвани различни подходи за автоматично опростяване на биомедицински текстове както на ниво изречение, така и на ниво документ. Бяха реализирани и сравнени голям езиков модел без допълнително обучение, дообучени модели FLAN-T5 и BioBART, многоетапен подход с класификация на операциите за опростяване, както и BioBART, подпомогнат от граф на знанията.

Получените резултати показват, че при задачата за опростяване на изречения най-добри резултати постига дообученият BioBART, който осигурява най-добър баланс между запазване на смисъла и степен на опростяване. FLAN-T5 показва високи стойности на BLEU и BERTScore, а големият езиков модел служи като подходяща отправна точка за сравнение. Многоетапният подход се оказва силно зависим от качеството на класификатора, а използването на граф на знанията подобрява резултатите само при ограничен брой примери.

При експериментите за опростяване на документи най-добри резултати постига дообучен BioBART. Всички експерименти върху документи имат по-добри резултати спрямо най-силният от експериментите върху изречения.

Като бъдеща работа могат да бъдат разгледани подобряване на класификатора на операциите, разширяване на графа на знанията, използване на по-богат документен контекст и оценяване на генерираните текстове от медицински специалисти и крайни потребители.

Получените резултати показват, че съвременните езикови модели могат успешно да се използват за автоматично опростяване на биомедицински текстове, като остават възможности за допълнително подобряване както при опростяването на отделни изречения, така и на цели документи.

8 Използвана литература

1. Bakker, J., & Kamps, J. (2024). *Cochrane-auto: An Aligned Dataset for the Simplification of Biomedical Abstracts*. <https://aclanthology.org/2024.tsar-1.5/>
2. Ermakova, L., Azarbonyad, H., Bakker, J., Vendeville, B., Kamps, J. (2026) *CLEF 2026 SimpleText Track*. In: Hauff, C., et al. *Advances in Information Retrieval. ECIR 2026*. <https://simpletext-project.com/2026/>
3. Ondov, B., Attal, K., & Demner-Fushman, D. (2022). *A Survey of Automated Methods for Biomedical Text Simplification*. Journal of the American Medical Informatics Association, 29(11), 1976–1988. <https://pmc.ncbi.nlm.nih.gov/articles/PMC10161533/>
4. Lewis, M. et al. (2020). *BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension*. ACL. <https://aclanthology.org/2020.acl-main.703/>
5. Raffel, C. et al. (2020). *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer*. Journal of Machine Learning Research. <https://jmlr.org/papers/v21/20-074.html>
6. Marturi, K. C., & Elwazzan, H. H. (2025). *LLM-Guided Planning and Summary-Based Scientific Text Simplification: DS@GT at CLEF 2025 SimpleText*. arXiv preprint arXiv:2508.11816. <https://arxiv.org/abs/2508.11816>